Elastic & food fact checking

Géraud Dugé de Bernonville

02/12/2022

Outline

Qualité des aliments & sécurité sanitaire

- Vache folle
- Grippe aviaire
- Perturbateurs endocriniens (pesticides, plastiques et autres substances chimiques...)
- OGM
- Allergènes (gluten, crustacés, oeufs, arachides, soja, ...)
- Cancérogènes (E171 - oxyde de titane ?)

Questions :

- Où trouve-t-on ces éléments ?
- Quelles catégories de produit sont les plus concernées ?
- Quelles marques ?

Mais surtout… Y a t'il du E171 dans la bière ?

Open Food Facts

Base de données sur les produits alimentaires faite par tout le monde, pour tout le monde.

Open Food Facts - Mobile

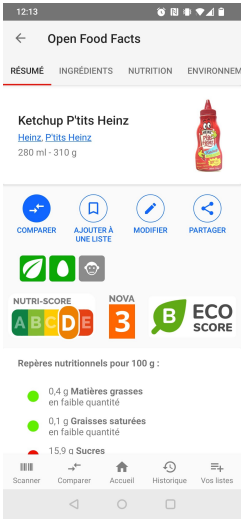

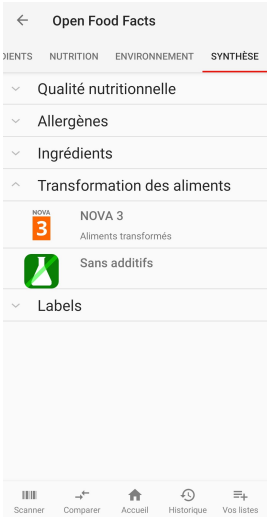

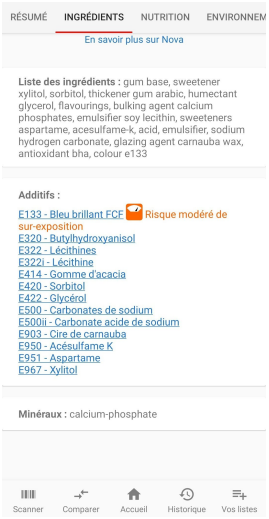

Ce qu'on aimerait avoir

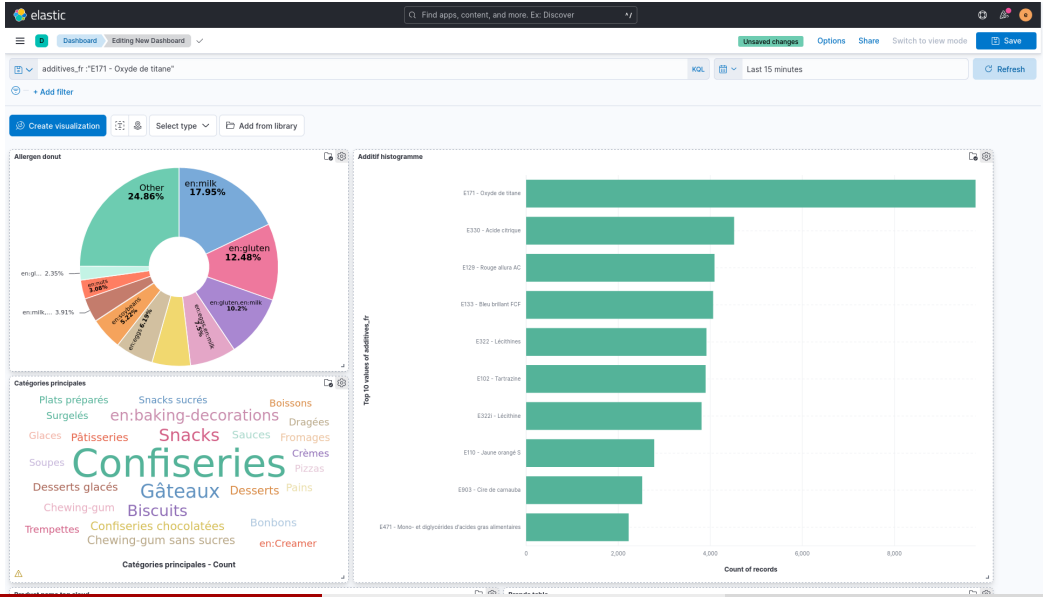

Elastic Stack

- Moteur de recherche
- Analyse et stockage de données

- Ingestion des données

- Visualisation

Topo Elasticsearch

Document JSON

```
{
  "name": "Chips au vinaigre",
  "category" : "apero",
  "lipides" : 20,
  "glucides" : 10,
  "proteines" : 5
}
```

API REST

```
<GET|POST|PUT|DELETE>
http[s]://<hostname>:<port>/[<index>]/[<type>]/[_<keyword>]]
```

- index
- type: _doc
- _keyword : _search, _mapping,...

Installation

Pré-requis

- Docker et plugin docker compose

Version 8.x

1. `cd elk-compose`
2. Lancer la stack: `docker compose up -d`
3. Ouvrir `http://localhost:5601` (`elastic` / `elastic_password`)
4. Aller dans Dev Tools (`http://localhost:5601/app/kibana#/dev_tools/console`)

Jouons avec Elasticsearch

Indexer un document

```
POST /store/_doc
{
  "name": "Chips au vinaigre",
  "category" : "apero",
  "lipides" : 20,
  "glucides" : 10,
  "proteines" : 5
}

POST /store/_doc
{
  "name": "Langues piquantes",
  "category" : "confiserie",
  "lipides" : 0,
  "glucides" : 90,
  "proteines" : 5
}
```

Requêter

```
GET /store/_search

GET /store/_search?q=langues

GET /store/_search
{
  "query": {
    "match": {
      "name": "langues"
    }
  }
}
```

Topo Logstash

Lancement

```
docker compose up logstash
```

Fichier conf

```
input { ... }
filter { ... }
output { ... }
```

Jouons avec Logstash - Données de test

1. Récupérer le fichier CSV `sample-fr.openfoodfacts.org.products.csv`
2. Vérifier le fichier `file-input.conf` dans le répertoire pipelines/student

```
input {
  file {
    path => "/data/*.csv"
    mode => "read"
    file_completed_action => "log"
    file_completed_log_path => "/data/input.log"
    exit_after_read => true
  }
}
```

3. Vérifier le fichier `debug-output.conf`

```
output {
  stdout { codec => "rubydebug" }
}
```

4. Lancer logstash

```
docker compose up --force-recreate logstash
```

5. Patienter…

Ajout du filtre CSV

1. Vérifier le fichier `filter.conf` dans le répertoire pipelines/student

```
filter {
    mutate { gsub => [ "message", "\"", "'" ] }
    csv {
        separator => "\t"
        autogenerate_column_names => false
        autodetect_column_names => true
        skip_header => true
        skip_empty_columns => true
    }
```

2. Mettre à jour la propriété `path.config` du fichier `pipelines/student/pipelines.yml`

```
path.config: "/pipelines/student/{file-input,debug-output,filter}.conf"
```

3. Relancer logstash

```
docker compose up --force-recreate logstash
```

Ajout de la sortie Elasticsearch

1. Vérifier le fichier `elastic-output.conf`

```
output {
    elasticsearch {
        hosts => [ "https://es01:9200" ]
        ssl => true
        cacert => "config/certs/ca/ca.crt"
        api_key => "${LOGSTASH_FOODFACTS_API_KEY}"
        index => "openfoodfacts"
        template => "/pipelines/student/openfoodfacts.template.json"
        template_name => "openfoodfacts"
        template_overwrite => true
        data_stream => false
    }
}
```

2. Mettre à jour la propriété `path.config` du fichier `pipelines/student/pipelines.yml`

```
path.config: "/pipelines/student/{file-input,filter,elastic-output}.conf"
```

3. Relancer logstash

```
docker compose up --force-recreate  logstash
```

Dans Kibana > Dev Tools

```
GET /openfoodfacts/_search
GET /openfoodfacts/_search?q=Snacks
```

Query time !

Nombre de catégories:

```
GET /openfoodfacts/_search
{
  "aggs": {
    "categories_count": {
      "value_count": {
        "field": "main_category"
      }
    }
  }
}
```

Query time !

Répartition des additifs par catégories:

```
GET /openfoodfacts/_search
{
  "aggs": {
    "par_categorie": {
      "terms": {
        "field": "main_category_fr",
        "size": 10
      },
      "aggs": {
        "par_additif": {
          "terms": {
            "field": "additives_fr"
          }
        }
      }
    }
  }
}
```

Problème de taille

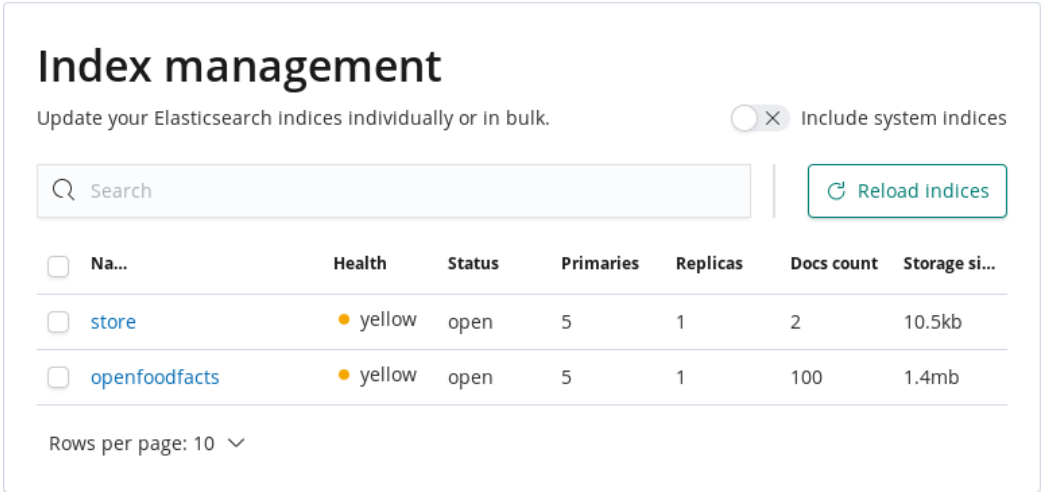

Configuration du mapping

```
DELETE openfoodfacts

PUT /openfoodfacts
{
    "settings" : {
        "number_of_shards": 3,
        "number_of_replicas": 0
    },
    "mappings": {
        "dynamic_templates": [
            {
                "strings": {
                    "match_mapping_type": "string",
                    "mapping": {
                        "type": "keyword"
                    }
                }
            }
        ]
    }
}
```

Jouons avec Kibana

Navigation dans les données

1. Configurer la data view, dans Stack Management, puis Data Views
   1. Renseigner openfoodfacts pour le nom
   2. Sélectionner — I don't want to use the time filter —
2. Accéder à l'onglet Discover
3. Sélectionner les champs `additives_fr`, `main_category_fr`,...

Kibana - Première visualisation

Nuage des principales catégories

1. Accéder à l'onglet Visualize
2. Sélectionner Aggregation based puis Tag Cloud
3. Configurer un bucket Tags
   - Aggregation = Terms
   - Field = `main_category_fr`
   - Size = 50
   - Custom Label = Catégories principales
4. Sauvegarder le widget

Kibana - Suite

Tableau des marques

1. Sélectionner Lens
2. Glisser le champ `brands` vers la visu
3. Sélectionner le type Table
4. Cliquer sur =Top 5 values of brands*
   - Number of values = 20
5. Sauvegarder

Kibana - Mmmmm Donut

Donut des allergènes

1. Sélectionner Lens
2. Glisser le champ `allergens` vers la visu
3. Sélectionner le type Donut
4. Cliquer sur =Top 5 values of brands
   - Number of values = 10
5. Sauvegarder

Kibana - Fin (?)

Histogramme des additifs

1. Sélectionner Bar horizontal
2. À vous de jouer…

Tag cloud des produits

On veut ça:

Dashboard

1. Ajouter tous les widgets dans un nouveau dashboard
2. Sauvegarder

Chargeons toute la base !

- L'objectif est de voir le résultat avec l'ensemble des données
- Pour éviter les doublons, on supprime l'index `openfoodfacts`
- Mettre à jour la propriété `path.config` du fichier `pipelines/student/pipelines.yml`
  ```
  path.config: "/pipelines/student/{file-input-full,filter,elastic-output}.conf"
  ```
- Relancer logstash
  ```
  docker compose up --force-recreate logstash
  ```
- Surveiller le dashboard (pour notre problématique, il est possible de filtrer sur `categories_tags :en\:beer*`)

Beer

Mission accomplie !

- Requêtes avec Elasticsearch
- Ingestion de données avec Logstash
- Visualisation avec Kibana

Pour aller plus loin

- Fixer problèmes d'import
  - Champs trop longs
  - Encodage
  - Guillemets mal positionnés
- Configurer l'analyseur pour utiliser la langue française
- Utiliser les informations de géolocalisation
- Utiliser les dates de création / modification
- …

Merci

Questions ?

- Twitter: @geraudster
- E-mail: geraud.dugedebernonville@zenika.com