# Elastic, dis-moi ce qu'il y a dans mon assiette

Géraud Dugé de Bernonville

10/03/2017

# Outline



# Qualité des aliments & sécurité sanitaire

- Vache folle
- Grippe aviaire
- Perturbateurs endocriniens (pesticides, plastiques et autres substances chimiques...)
- OGM
- Allergènes (gluten, crustacés, oeufs, arachides, soja, ...)
- Cancérogènes (E171 - oxyde de titane ?)

Questions :

- Où trouve-t-on ces éléments ?
- Quelles catégories de produit sont les plus concernées ?
- Quelles marques ?

# Mais surtout… Y a t'il du E171 dans la bière ?

# Open Food Facts

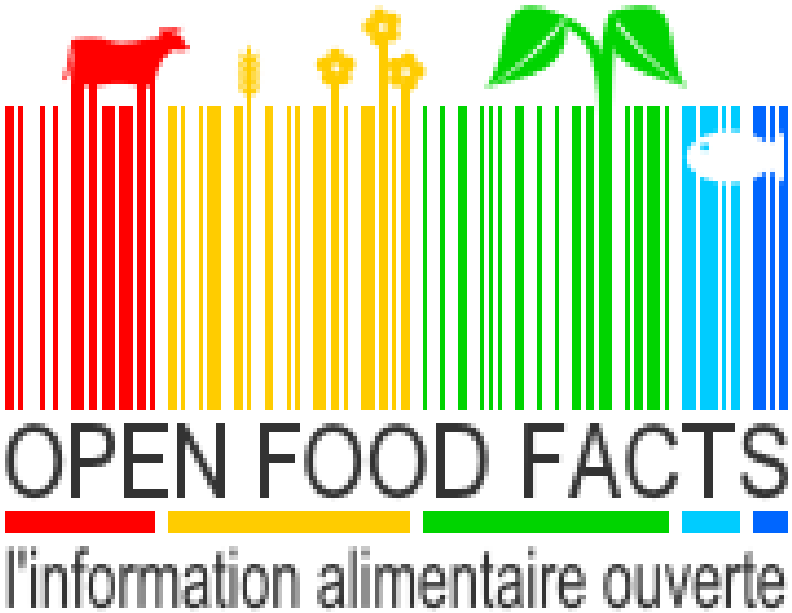


Base de données sur les produits alimentaires faite par tout le monde, pour tout le monde.

# Open Food Facts - Mobile

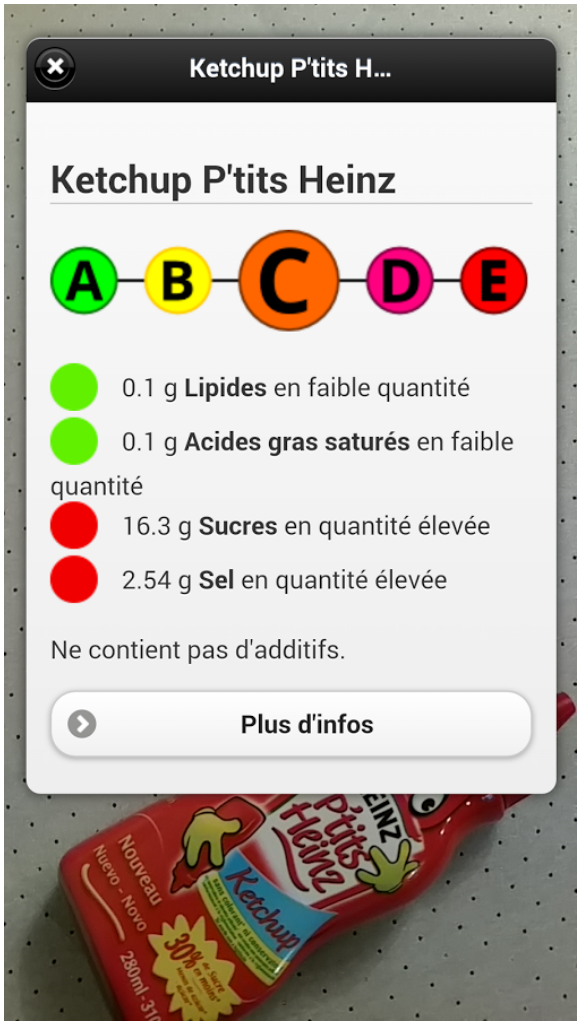


acide d'ammonium, diphosphate disodique, carbonate acide de sodium ), sel, lactose et protéines de lait.

**Traces éventuelles :** Sésame

**Additifs :**

- E331 - Citrates de sodium
- E333 - Citrates de calcium
- E330 - Acide citrique
- E440 - Pectines
- E415 - Gomme xanthane
- E322 - Lécithines
- E503 - Carbonates d'ammonium
- E450 - Diphosphate disodique
- E500 - Carbonates de sodium

**Informations nutritionnelles**

**Taille d'une portion :** 1 gâteau (12,5g)

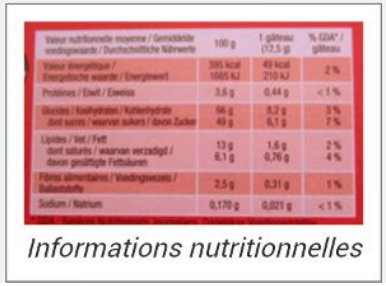

*Informations nutritionnelles*

# Ce qu'on aimerait avoir

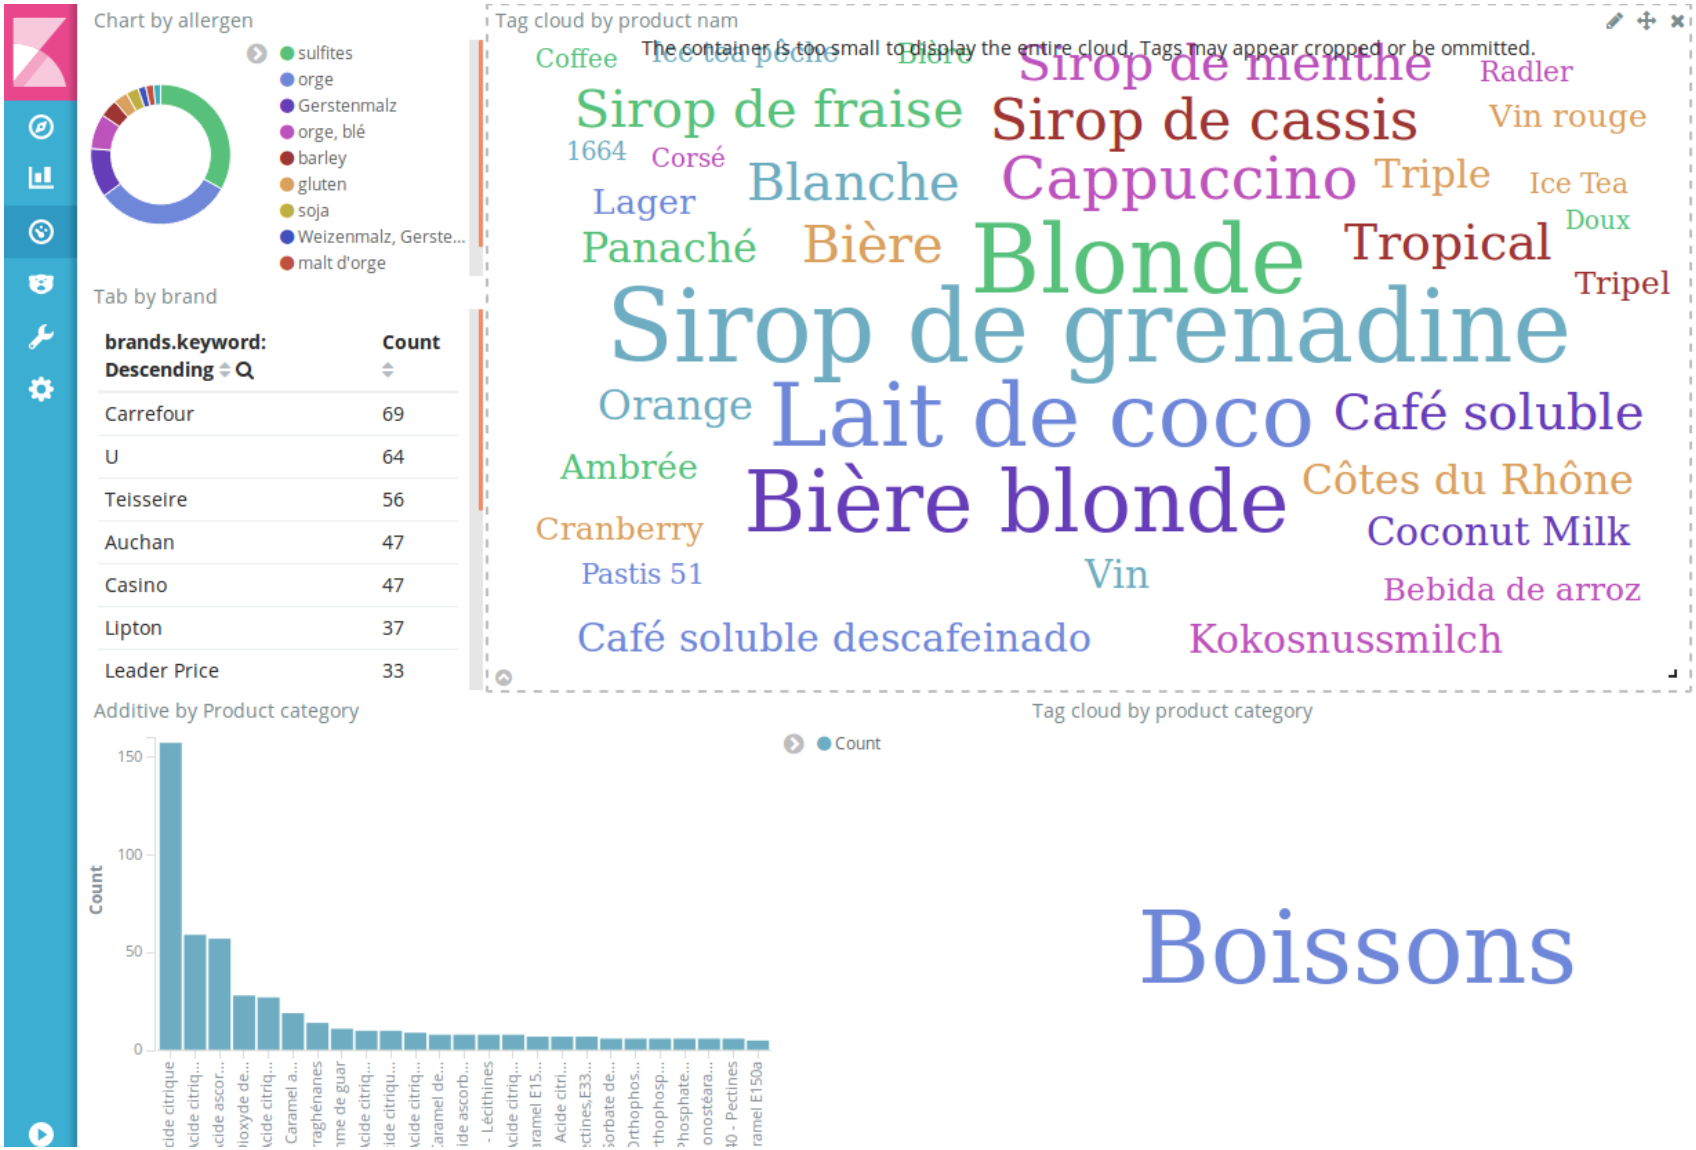

# ELK

- Moteur de recherche
- Analyse et stockage de données

- Ingestion des données

- Visualisation

# Topo Elasticsearch

## Document JSON

```
{
  "name": "Chips au vinaigre",
  "category" : "apero",
  "lipides" : 20,
  "glucides" : 10,
  "proteines" : 5
}
```

## API REST

```
<GET|POST|PUT|DELETE>
http[s]://<hostname>:<port>/[<index>/[<type>]/[_<keyword>]]
```

- index
- type
- _keyword : _search, _mapping,...

# Installation

## Pré-requis

- Une JVM 1.8 minimum doit être installée
- La variable `JAVA_HOME` doit être définie

## Version 5.2.2

1. Récupérer les archives et les décompresser
2. Ajouter la propriété suivante dans `elasticsearch/config/elasticsearch.yml`

   ```
   cluster.name: <user>-cluster
   ```
3. Lancer elasticsearch[.bat], kibana[.bat]
4. Ouvrir `http://localhost:5601`
5. Aller dans Dev Tools

# Jouons avec Elasticsearch

## Indexer un document

```
POST /store/food
{
  "name": "Chips au vinaigre",
  "category" : "apero",
  "lipides" : 20,
  "glucides" : 10,
  "proteines" : 5
}

POST /store/food
{
  "name": "Langues piquantes",
  "category" : "confiserie",
  "lipides" : 0,
  "glucides" : 90,
  "proteines" : 5
}
```

## Requêter

```
GET /store/food/_search

GET /store/_search?q=langues

GET /store/_search
{
  "query": {
    "match": {
      "name": "langues"
    }
  }
}
```

# Topo Logstash

## Lancement

```
logstash -f logstash.conf
```

## Fichier conf

```
input { ... }
filter { ... }
output { ... }
```

# Jouons avec Logstash - Données de test

1. Récupérer le fichier CSV

   `sample-fr.openfoodfacts.org.products.csv`

2. Récupérer le fichier `food.conf`

```
input {
  file {
    path => "/home/geraud/data/openfoodfacts/*.csv"
    start_position => "beginning"
    sincedb_path => "/home/geraud/data/openfoodfacts/sincedb"
  }
}

output {
  stdout { codec => "rubydebug" }
}
```

3. Lancer logstash

   `logstash -f food.conf`

4. Copier le CSV d'exemple dans le répertoire data/openfoodfacts
5. Patienter...

# Ajout du filtre CSV

1. Ajouter le filter suivant (copier depuis `filter.conf`)

```
filter {
  if [message] =~ /^code        url/ {
    drop {}
  }
  csv {
    columns => ["code","url","creator","created_t","created_datetime","last_mo
    separator => "      "
    autogenerate_column_names => false
  }
}
```

2. Supprimer le fichier `since_db`
3. Relancer logstash

# Ajout de la sortie Elasticsearch

1. Ajouter l'output suivant

   ```
   elasticsearch { }
   ```

2. Relancer logstash

## Dans Kibana > Dev Tools

```
GET /logstash-*/_search
GET /logstash-*/_search?q=e171
```

# Query time !

## Nombre de catégories:

```
GET /logstash-*/_search
{
  "aggs": {
    "categories_count": {
      "value_count": {
        "field": "main_category.keyword"
      }
    }
  }
}
```

# Query time !

Répartition des additifs par catégories:

```
GET /logstash-*/_search
{
  "aggs": {
    "par_categorie": {
      "terms": {
        "field": "main_category_fr.keyword",
        "size": 10
      },
      "aggs": {
        "par_additif": {
          "terms": {
            "field": "additives_fr.keyword"
          }
        }
      }
    }
  }
}
```

# Jouons avec Kibana

## Navigation dans les données

1. Configurer l'index, décocher Index contains time-based events
2. Accéder à l'onglet Discover
3. Sélectionner les champs `additives_fr`, `main_category_fr`,...

## Première visualisation - Nuage des principales catégories

1. Accéder à l'onglet Visualize
2. Sélectionner Tag Cloud
3. Configurer un bucket Tags
   - Aggregation = Terms
   - Field = `main_category_fr.keyword`
   - Size = 50
   - Custom Label = Catégories principales
4. Sauvegarder le widget

# Kibana - Suite

## Tableau des marques

1. Sélectionner Table
2. Créer un bucket Split Rows
   - Aggregation = Terms
   - Field = `brands.keyword`
   - Size = 20
   - Custom Label = Marques
3. Sauvegarder

# Kibana - Mmmmm Donut

## Donut des allergènes

1. Sélectionner Pie chart
2. Créer un bucket Split Slices
   - Aggregation = Terms
   - Field = `allergens.keyword`
   - Size = 10
   - Custom Label = Allergènes
   - Options > Sélectionner Donut
3. Sauvegarder

# Kibana - Fin (?)

## Histogramme des additifs

1. Sélectionner Vertical Bar Chart
2. À vous de jouer…

## Tag cloud des produits

On veut ça:

# Dashboard

1. Ajouter tous les widgets dans un nouveau dashboard
2. Sauvegarder

# Chargeons toute la base !

- L'objectif est de voir le résultat avec l'ensemble des données
- Pour éviter les doublons, on supprime l'index `logstash-*`
- Supprimer l'output `stdout`
- Décompresser ensuite le fichier `fr.openfoodfacts.org.products.csv.gz` dans votre répertoire `data`
- Lancer logstash

# Beer


Mission accomplie !

- Requêtes avec Elasticsearch
- Ingestion de données avec Logstash
- Visualisation avec Kibana

# Pour aller plus loin

- Fixer problèmes d'import
  - Champs trop longs
  - Encodage
  - Guillemets mal positionnés
- Découper les champs, par exemple :
  - E330 - Acide citrique,E150c - Caramel ammoniacal,E300 - Acide ascorbique
  - Frais,Produits laitiers,Desserts,Fromages,Fromages blancs,Fromages-blancs-aromatises
- Configurer l'analyseur pour utiliser la langue française
- Utiliser les informations de géolocalisation

# Merci

?

Questions